

Matriz Estratégica de Modelos y Análisis de Costos de IA

1. Matriz de Selección de Modelos por Tarea

Para este ecosistema se estandarizó la arquitectura sobre GPT-4o mini para todas las tareas de procesamiento generativo, priorizando baja latencia, precisión en el seguimiento de directrices clínicas y optimización presupuestaria.

<i>Tarea del Ecosistema</i>	<i>Modelo Seleccionado</i>	<i>Justificación Técnica y Operativa</i>	<i>Modelo Alternativo Descartado</i>	<i>Motivo de Descarte de la Alternativa</i>
Generación de copys comerciales con contexto RAG	GPT-4o mini	Procesa eficientemente la inyección de datos clínicos de Notion, respeta el límite de longitud y responde en < 1.5 s.	GPT-4o (Standard)	Sobrecosto injustificado (~33x más caro en input) para generación de textos cortos.
Adaptación a formatos de salida (Telegram / HTML Email)	GPT-4o mini	Genera estructuras Markdown y etiquetas HTML limpias sin requerir llamadas adicionales.	Claude 3.5 Sonnet	Mayor costo por token y latencia innecesaria para formateo estructurado.
Generación de contingencia (Fallback)	Directiva local Make (Fallback)	Texto parametrizado predeterminado sin consumo de API para casos de caída del servicio.	Modelo secundario (ej. Gemini Flash)	Complejidad innecesaria en la gestión de credenciales y llamadas redundantes.

2. Estructura de Precios de Referencia (OpenAI API)

GPT-4o mini:

Input (Entrada / Prompt + Contexto RAG): USD 0.15 por 1M tokens (USD 0.00015 / 1k tokens).

Output (Salida / Límite configurado): USD 0.60 por 1M tokens (USD 0.00060 / 1k tokens).

GPT-4o (Modelo base de comparación):

Input: USD 5.00 por 1M tokens.

Output: USD 15.00 por 1M tokens.

3. Conclusión Estratégica del Costo

Eficiencia y Viabilidad: La fijación de max_tokens: 400 junto con GPT-4o mini asegura un techo de costo predecible y reduce el gasto de cómputo en más de un 96% frente a modelos insignia.

Escalabilidad: El costo por campaña generada y aprobada es inferior a USD 0.0004, permitiendo a la clínica escalar su volumen de comunicaciones sin impacto financiero.